Relatório: Análise de Fairness no Sistema de Crédito

Ética em Inteligência Artificial — Toolkit de Bias e Fairness (Parte 3/3)

Jefferson Cunha — jefferson.cunha@ufpe.br

Disciplina: Ética e Inteligência Artificial — 2º sem/2026 — Prof. Geber Ramalho

Metodologia. Simulei 2000 clientes (60% homens, 40% mulheres; `seed`=42). O *score* base combina renda, *score* de crédito, razão dívida/renda e idade. Para mulheres, o *score* é multiplicado por `VIES_GENERO`. A decisão é `score > threshold`, e o *ground truth* é `score_base > 0,5`. DPD = $|\text{taxa}_H - \text{taxa}_M|$.

1. Sem viés e com viés forte

- `VIES_GENERO` = **1,0.** Há diferença pequena: homens 85,9% e mulheres 82,4% (DPD = 0,035). Não há viés intencional; a diferença vem da **variabilidade amostral**. Gênero é sorteado independentemente das *features*, então a diferença tende a zero com amostras maiores. A acurácia é 100%, pois a decisão coincide com o *ground truth*.
- `VIES_GENERO` = **0,8.** Homens 85,9% e mulheres 34,2%: diferença de **51,7 pontos percentuais** (DPD ≈ 0,52). Mulheres têm taxa de aprovação 60% menor, e a acurácia cai para 80,8%.
- **DPD na prática.** É a diferença entre as taxas de aprovação dos grupos. Mede o quanto o resultado depende do grupo, **sem olhar se a decisão estava correta**. DPD = 0,52 significa que, em cada 100 candidatas e 100 candidatos, "aprovam-se" ∼52 mulheres a menos.

2. Thresholds diferentes

- `THRESHOLD_MULHERES` = **0,45.** Na célula de mitigação do *notebook* (viés 1,0), o DPD **piora** de 0,035 para 0,087 (mulheres 94,6% vs. homens 85,9%), e a acurácia cai de 100% para 95,2% (perda de 4,8 p.p.). Isso porque se corrige um viés que não existe. Com viés 0,8, o DPD cai de 0,517 para 0,250 e a acurácia **sobe** de 80,8% para 91,5%: reduz a disparidade, mas não a elimina.
- **Combinação ótima (viés 0,8, homens = 0,50).** `THRESHOLD_MULHERES` = **0,39** dá DPD = 0,007 e acurácia = 98,4% (bem acima de 70%).
- **Preço de DPD ≈ 0.** Apenas **1,6 p.p.** de acurácia (100% → 98,4%). Aqui o custo é baixo porque o viés é uma distorção multiplicativa conhecida e o corte corrige exatamente essa distorção ($0{,}5 \times 0{,}8 = 0{,}4$). O "custo" é medido contra o *ground truth* do próprio simulador; em dados reais ele seria incerto.

Thr. mulheres (viés 0,8)	0,36	0,39	0,40	0,45
DPD	0,087	0,007	0,035	0,250
Acurácia	95,2%	98,4%	100%	91,5%

3. Reflexões

- **É ético usar thresholds por gênero?** Em geral, não. Tratamento explícito por gênero é disparate treatment e viola a LGPD (art. 20) e a legislação antidiscriminatória. Corrige-se o sintoma e não a causa, e o ajuste só funciona se o viés for conhecido. O correto é remover a fonte do viés (dados, *features*, proxies), auditar e usar mitigação que não use atributo protegido na decisão (reponderar dados, restrições de fairness no treino). Em contextos de ação afirmativa, tal medida deve ser transparente, temporária e juridicamente respaldada.
- **Outras fontes de viés.** Dados históricos já discriminatórios; *proxies* (CEP, profissão, renda, tipo de contrato, histórico de crédito mais curto); representatividade desigual; rótulos enviesados (inadimplência observada só entre aprovados); desbalanceamento de classes; interseções (gênero × raça × idade); processo humano de revisão.
- **Explicação a um gerente focado em lucro.** Viés custa dinheiro: negamos crédito a bons pagadores (perda de receita e de clientes) e ficamos expostos a multas, processos e dano à reputação. Na simulação, corrigir o viés custou 1,6 p.p. de acurácia, enquanto o viés não corrigido custou 19,2 p.p. (100% → 80,8%). Fairness e lucro não são antagonistas quando o viés é ruído; o trade-off real surge quando a desigualdade é estrutural, e aí a decisão é de política e risco, e não só técnica.

Apêndice A — Simulações e gráficos do notebook

Todos os resultados abaixo vêm do notebook `jwc_toolkit_bias_fairness_p3.ipynb`. Convenções: **DPD** = diferença de paridade demográfica; acurácia medida contra o *ground truth* `score_base > 0,5`; "thr." = *threshold*.

A.1 Célula 43 — Varredura viés × threshold das mulheres

Para cada par (viés ∈ {0,7; 0,85; 0,9; 1,0}, thr. mulheres ∈ {0,40; 0,45; 0,50; 0,55}) gera-se uma nova amostra de 2000 clientes (thr. dos homens fixo em 0,50) e calculam-se taxas de aprovação, DPD e acurácia.

Viés	Thr. M.	Aprov. H (%)	Aprov. M (%)	DPD	Acur. (%)
0.70	0.40	85.5	56.0	0.296	87.7
0.70	0.45	85.0	28.7	0.563	78.0
0.70	0.50	83.2	13.5	0.697	72.2
0.70	0.55	83.7	5.4	0.783	68.6
0.85	0.40	83.0	90.1	0.071	97.4
0.85	0.45	83.9	76.7	0.071	96.2
0.85	0.50	85.7	49.1	0.365	85.8
0.85	0.55	83.6	25.3	0.583	77.0
0.90	0.40	85.4	96.3	0.109	95.2
0.90	0.45	85.9	83.6	0.023	100.0
0.90	0.50	84.0	63.2	0.208	91.0
0.90	0.55	85.6	40.8	0.448	80.8
1.00	0.40	84.0	99.6	0.157	93.9
1.00	0.45	85.3	95.8	0.105	95.3
1.00	0.50	84.8	85.6	0.009	100.0
1.00	0.55	85.0	67.0	0.179	93.0

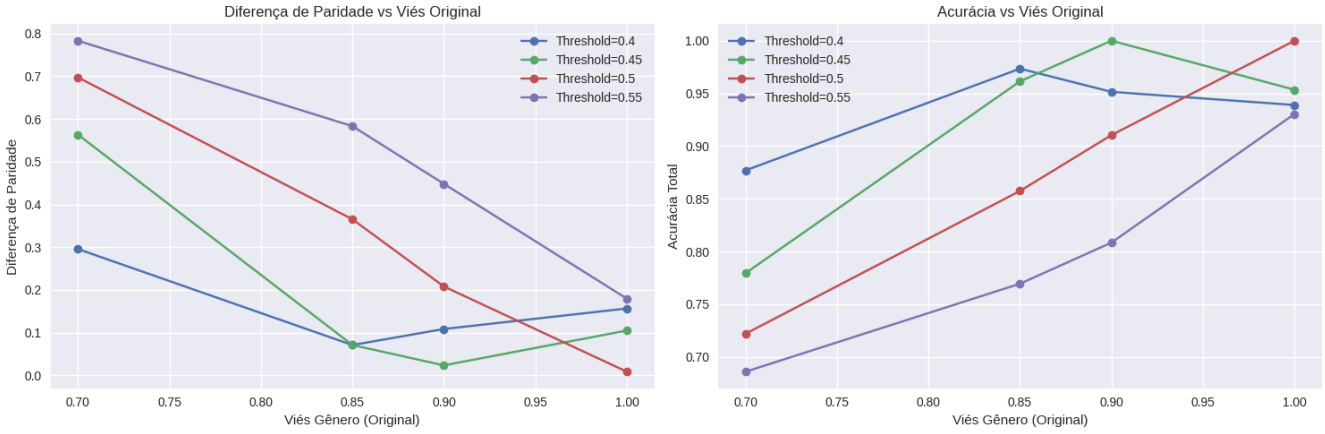


Figura 1: Célula 43. Esquerda: DPD × viés original, uma curva por thr. das mulheres. Direita: acurácia × viés.

Interpretação. (i) Com thr. 0,50 (curva vermelha), o DPD cai de 0,70 (viés 0,7) para ≈ 0 (viés 1,0) e a acurácia sobe de 72% para 100%: sem correção, quanto maior o viés, pior o sistema. (ii) Thr. baixos compensam o viés: com viés 0,7, passar de 0,50 para 0,40 reduz o DPD de 0,70 para 0,30 e eleva a acurácia de 72% para 88%. (iii) Correção em excesso prejudica: com viés 1,0, thr. 0,40 e 0,45 **aumentam** o DPD (0,16 e 0,10) e reduzem a acurácia (94% e 95%), pois se corrige um viés inexistente. (iv) O melhor thr. depende do viés: 0,45 para viés 0,9 (DPD 0,023; 100%), 0,40–0,45 para 0,85 e 0,50 para 1,0. *Ressalva:* cada combinação usa amostra aleatória nova (sem `seed`), logo valores variam entre execuções (ex.: viés 1,0/thr. 0,50 dá DPD 0,009 aqui e 0,035 na célula 48).

A.2 Célula 47 — Taxas de aprovação por gênero

Interpretação. A taxa dos homens fica estável (≈83–86%), pois o thr. masculino e seu *score* não mudam. Na esquerda, com viés 0,85, a taxa feminina cai de 90,1% (thr. 0,40) para 25,3% (0,55) e cruza a masculina perto de 0,42: abaixo desse ponto há *sobrecorreção* (mulheres aprovadas mais que homens). Na direita, com thr. igual para ambos, a taxa feminina sobe de 13,5% (viés 0,7) para 85,6% (viés 1,0) e converge à masculina: o viés multiplicativo desloca toda a distribuição de *scores* das mulheres para baixo, e pequenas penalizações geram quedas grandes porque muitos *scores* ficam próximos do corte. *Nota:* o texto da célula 45 cita 47,4%/76,9%/92,9%, mas a tabela da célula 43 mostra 49,1%/76,7%/90,1% (thr. 0,50/0,45/0,40); os valores variam por falta de `seed`.

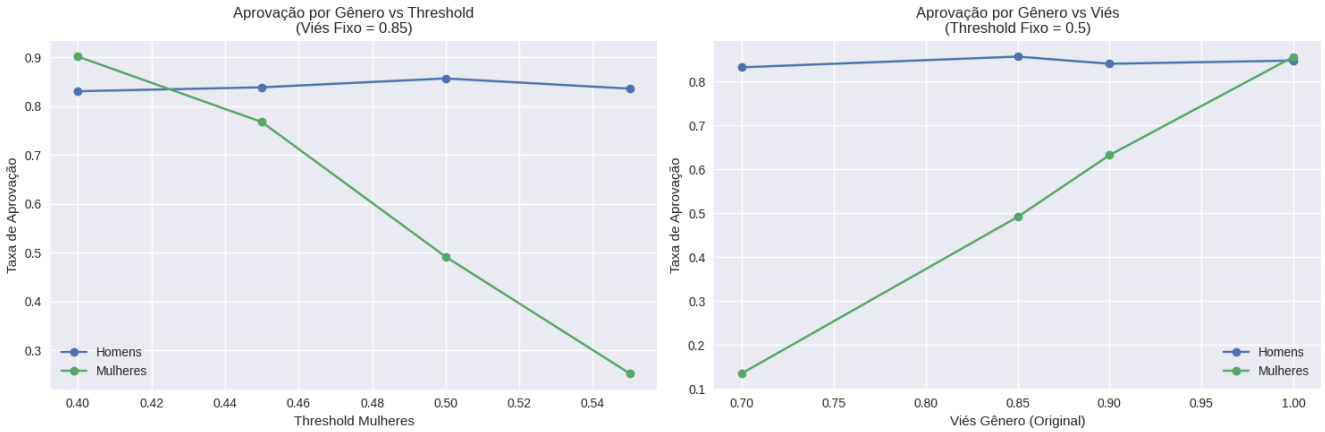


Figura 2: Célula 47, a partir da tabela da célula 43. Esquerda: taxas × thr. das mulheres (viés 0,85). Direita: taxas × viés (thr. 0,50).

A.3 Célula 48 — Viés 1,0 vs. 0,8 (mesma amostra, `seed`=42)

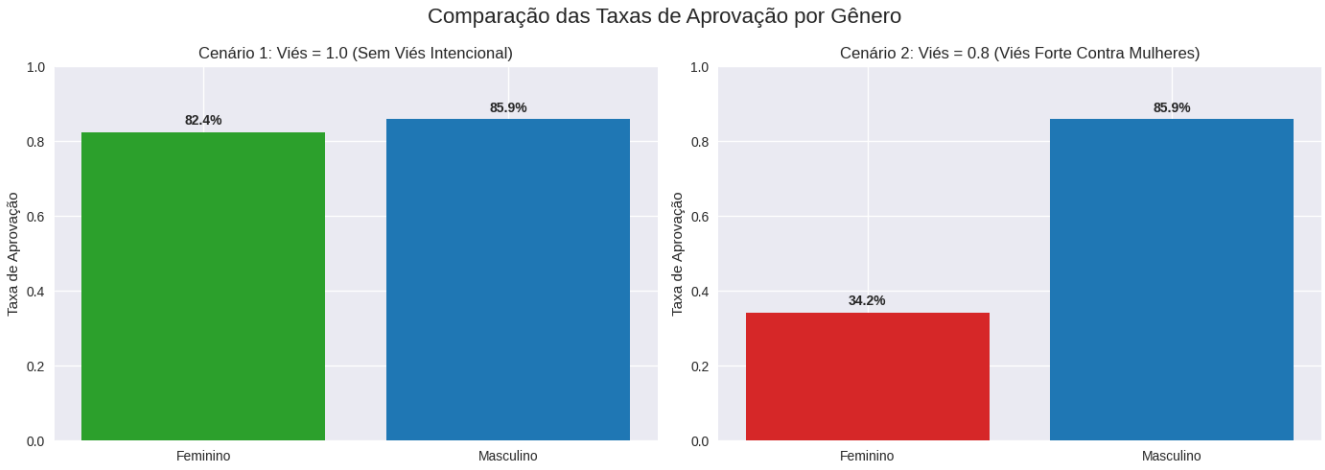


Figura 3: Célula 48. Taxas de aprovação por gênero com viés 1,0 e 0,8 (mesmos clientes, thr. 0,50).

Resultado impresso: DPD (viés 1,0) = 3,5%; DPD (viés 0,8) = 51,7%. Como a `seed` fixa gera exatamente as mesmas pessoas, a única mudança entre os painéis é o fator 0,8 aplicado ao *score* feminino: mulheres passam de 82,4% para 34,2% e homens ficam em 85,9%. Isso isola o efeito do viés. A diferença de 3,5% no painel esquerdo é puro acaso amostral.

A.4 Célula 49 — Trade-off fairness × acurácia (viés 0,8)

Resultado impresso:

- thr. 0,50 (sem mitigação): DPD 51,7%, acurácia 80,8%;
- thr. 0,45: DPD 25,0%, acurácia 91,5%;
- melhor thr. (mínimo DPD com acurácia $> 70\%$) = 0,39: DPD 0,7%, acurácia 98,4%;
- "Preço" impresso: −17,5%. O sinal negativo indica que a acurácia **aumenta** 17,5 p.p. em relação ao modelo sem mitigação; contra o modelo sem viés (100%), o custo é 1,6 p.p.

Interpretação. O DPD tem mínimo em 0,39 (*valley* da curva vermelha) e a acurácia máxima (100%) em 0,40: como $0{,}5 \times 0{,}8 = 0{,}4$, o thr. 0,40 anula exatamente o viés, e o ponto de DPD mínimo difere ligeiramente pela discretização dos *scores* amostrados. Acima de 0,40 a acurácia cai e o DPD cresce quase linearmente; abaixo, ocorre sobrecorreção, aprovando mulheres que o *score* base reprovaria. Neste cenário fairness e acurácia caminham juntas, porque o "*ground truth*" é o *score* sem viés.

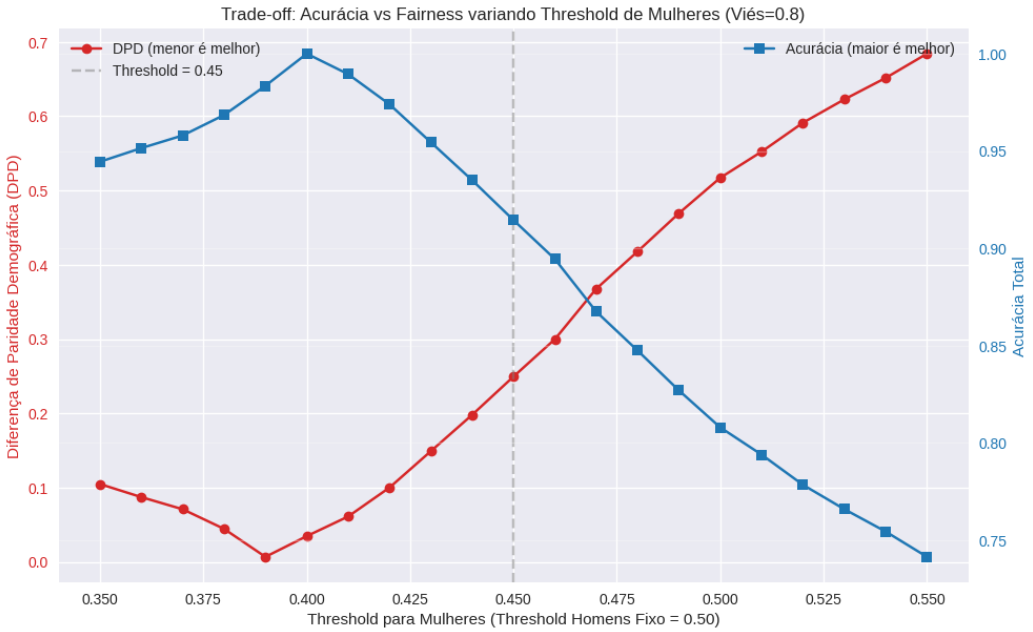


Figura 4: Célula 49. DPD (vermelho, eixo esquerdo) e acurácia (azul, eixo direito) × thr. das mulheres (0,35–0,55; homens = 0,50).