Relatório: Análise de Fairness no Sistema de Crédito

Ética em Inteligência Artificial — Toolkit de Bias e Fairness (Parte 3/3)

Jefferson Cunha — `jefferson.cunha@ufpe.br`

Disciplina: Ética e Inteligência Artificial — 2º sem/2026 — Prof. Geber Ramalho

Metodologia. Simulei 2000 clientes (60% homens, 40% mulheres; `seed`=42). O *score* base combina renda, *score* de crédito, razão dívida/renda e idade. Para mulheres, o *score* é multiplicado por `VIES_GENERO`. A decisão é `score > threshold`, e o *ground truth* é `score_base > 0,5`. DPD = $|\text{taxa}_H - \text{taxa}_M|$.

1. Sem viés e com viés forte

Com `VIES_GENERO` = 1,0 há diferença pequena (homens 85,9%, mulheres 82,4%; DPD 0,035), devida à variabilidade amostral. Com 0,8, as mulheres caem para 34,2% e a diferença chega a **51,7 p.p.**. O DPD mede o quanto o resultado depende do grupo, sem olhar se a decisão estava correta. Detalhes no Apêndice A.1.

2. Thresholds diferentes

Com `THRESHOLD_MULHERES` = 0,45: no *notebook* (viés 1,0) o DPD piora (0,035 → 0,087) e a acurácia cai de 100% para 95,2%; com viés 0,8 o DPD cai (0,517 → 0,250) e a acurácia sobe (80,8% → 91,5%). A melhor combinação (homens 0,50; mulheres **0,39**) dá DPD 0,007 e acurácia 98,4%; o "preço" de fairness ≈ perfeita é de só **1,6 p.p.** de acurácia (Apêndice A.2).

3. Reflexões éticas e práticas

- **Thresholds diferentes por gênero são éticos?** É uma questão complexa. Pela *equidade de resultados* (paridade demográfica), ajustar thresholds corrige distorções sistêmicas e promove justiça compensatória. Mas, no Brasil (LGPD, princípio da não discriminação, art. 6º, IX) e nos EUA (*Equal Credit Opportunity Act*), usar atributo protegido para aplicar regras distintas na concessão de crédito caracteriza tratamento discriminatório direto. O ideal não é "baixar a régua" no final, e sim corrigir vieses estruturais nos dados, remover variáveis *proxy* ou treinar com restrições de fairness, para que o modelo trate indivíduos de forma igualitária por construção.
- **Outros fatores de viés.** Algoritmos raramente usam gênero diretamente; o viés se esconde em *proxies*: histórico de renda e emprego (pausas de carreira, licença-maternidade), CEP (raça e classe, viés espacial), profissão/setor (setores feminizados com remuneração média distinta) e viés de amostragem (histórico de mais crédito a homens leva o modelo a confiar mais no perfil masculino).
- **Explicação ao gerente focado em lucro.** Foco em risco de longo prazo e oportunidade perdida: (i) *custo de oportunidade*, pois o modelo enviesado gera falsos negativos e rejeita boas pagadoras; (ii) *risco regulatório*, pois multas e auditorias custam mais que a pequena perda de acurácia; (iii) *reputação*, pois escândalo de discriminação afeta a marca e afasta clientes. Perder alguns pontos de acurácia é aceitar um risco um pouco maior de inadimplência (mais falsos positivos) para ampliar a base de clientes saudáveis e garantir conformidade. Na simulação, corrigir o viés custou 1,6 p.p., e não corrigir custou 19,2 p.p. (100% → 80,8%).

4. *Lessons learned*

Os artigos apresentaram novidades quanto às diferentes categorias de vieses algorítmicos e mostraram, de forma material, que há complexidade e implicações éticas na forma de resolvê-los: seja com a introdução de compensadores após o resultado, o que implica reduzir a acurácia do modelo; seja, em contrapartida, pela ausência de dados suficientes para compensar um treinamento menos enviesado.

Apêndice A — Detalhamento das Seções 1 e 2

A.1 Sem viés e com viés forte (detalhe da Seção 1)

- `VIES_GENERO` = **1,0.** Há diferença pequena: homens 85,9% e mulheres 82,4% (DPD = 0,035). Não há viés intencional; a diferença vem da **variabilidade amostral**. Gênero é sorteado independentemente das *features*, então a diferença tende a zero com amostras maiores. A acurácia é 100%, pois a decisão coincide com o *ground truth*.
- `VIES_GENERO` = **0,8.** Homens 85,9% e mulheres 34,2%: diferença de **51,7 pontos percentuais** (DPD $\approx$ 0,52). Mulheres têm taxa de aprovação 60% menor, e a acurácia cai para 80,8%.
- **DPD na prática.** É a diferença entre as taxas de aprovação dos grupos. Mede o quanto o resultado depende do grupo, **sem olhar se a decisão estava correta**. DPD = 0,52 significa que, em cada 100 candidatas e 100 candidatos, "aprovam-se" $\sim$52 mulheres a menos.

A.2 Thresholds diferentes (detalhe da Seção 2)

- `THRESHOLD_MULHERES` = **0,45.** Na célula de mitigação do *notebook* (viés 1,0), o DPD **piora** de 0,035 para 0,087 (mulheres 94,6% vs. homens 85,9%), e a acurácia cai de 100% para 95,2% (perda de 4,8 p.p.). Isso porque se corrige um viés que não existe. Com viés 0,8, o DPD cai de 0,517 para 0,250 e a acurácia **sobe** de 80,8% para 91,5%: reduz a disparidade, mas não a elimina.
- **Combinação ótima (viés 0,8, homens = 0,50).** `THRESHOLD_MULHERES` = **0,39** dá DPD = 0,007 e acurácia = 98,4% (bem acima de 70%).
- **Preço de DPD $\approx$ 0.** Apenas **1,6 p.p.** de acurácia (100% $\rightarrow$ 98,4%). Aqui o custo é baixo porque o viés é uma distorção multiplicativa conhecida e o corte corrige exatamente essa distorção ($0{,}5 \times 0{,}8 = 0{,}4$). O "custo" é medido contra o *ground truth* do próprio simulador; em dados reais ele seria incerto.

Thr. mulheres (viés 0,8)	0,36	0,39	0,40	0,45
DPD	0,087	0,007	0,035	0,250
Acurácia	95,2%	98,4%	100%	91,5%

Apêndice B — Simulações e gráficos do notebook

Todos os resultados abaixo vêm do notebook `jwc_toolkit_bias_fairness_p3.ipynb`. Convenções: **DPD** = diferença de paridade demográfica; acurácia medida contra o *ground truth* `score_base > 0,5`; "thr." = *threshold*.

B.1 Célula 43 — Varredura viés × threshold das mulheres

Para cada par (viés ∈ {0,7; 0,85; 0,9; 1,0}, thr. mulheres ∈ {0,40; 0,45; 0,50; 0,55}) gera-se uma nova amostra de 2000 clientes (thr. dos homens fixo em 0,50) e calculam-se taxas de aprovação, DPD e acurácia.

Viés	Thr. M.	Aprov. H (%)	Aprov. M (%)	DPD	Acur. (%)
0.70	0.40	85.5	56.0	0.296	87.7
0.70	0.45	85.0	28.7	0.563	78.0
0.70	0.50	83.2	13.5	0.697	72.2
0.70	0.55	83.7	5.4	0.783	68.6
0.85	0.40	83.0	90.1	0.071	97.4
0.85	0.45	83.9	76.7	0.071	96.2
0.85	0.50	85.7	49.1	0.365	85.8
0.85	0.55	83.6	25.3	0.583	77.0
0.90	0.40	85.4	96.3	0.109	95.2
0.90	0.45	85.9	83.6	0.023	100.0
0.90	0.50	84.0	63.2	0.208	91.0
0.90	0.55	85.6	40.8	0.448	80.8
1.00	0.40	84.0	99.6	0.157	93.9
1.00	0.45	85.3	95.8	0.105	95.3
1.00	0.50	84.8	85.6	0.009	100.0
1.00	0.55	85.0	67.0	0.179	93.0

Cenários destacados (retângulos vermelhos).

- **C1 — (viés 0,7; thr. M. 0,40):** mesmo com thr. menor para as mulheres, se o viés for alto a aprovação delas segue significativamente baixa (56,0%) em comparação a 85,5% para os homens (DPD 0,296).
- **C2 — (viés 1,0; thr. M. 0,50):** basta eliminar o viés para que, em cenários como este, a taxa de aprovação das mulheres ultrapasse a dos homens (85,6% contra 84,8%). A diferença é pequena (DPD 0,009) e está dentro da variação amostral, então indica aprovação praticamente igual.

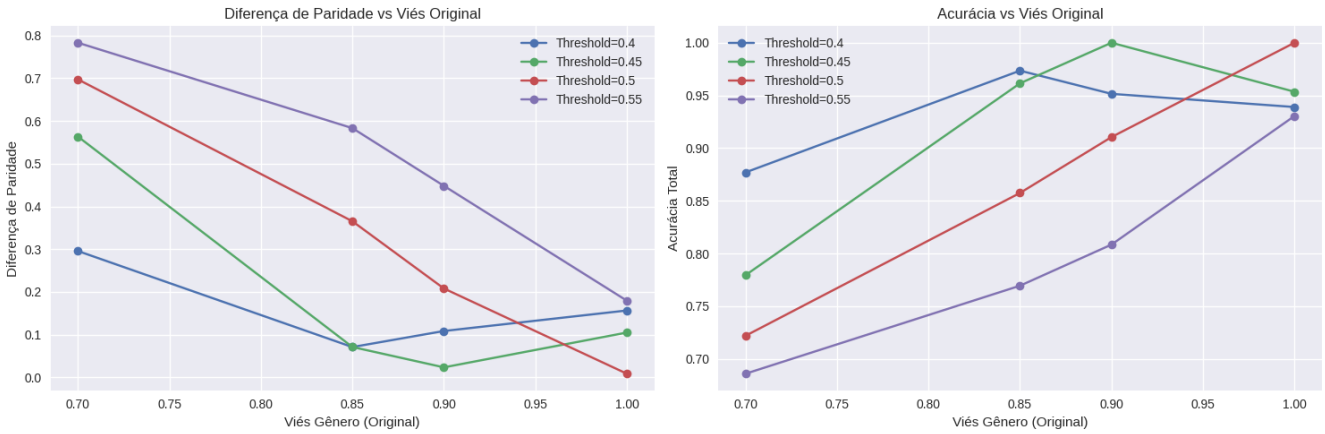


Figura 1: Célula 43. Esquerda: DPD × viés original, uma curva por thr. das mulheres. Direita: acurácia × viés.

Interpretação. (i) Com thr. 0,50 (curva vermelha), o DPD cai de 0,70 (viés 0,7) para ≈ 0 (viés 1,0) e a acurácia sobe de 72% para 100%: sem correção, quanto maior o viés, pior o sistema. (ii) Thr. baixos compensam o viés: com viés 0,7, passar de 0,50 para 0,40 reduz o DPD de 0,70 para 0,30 e eleva a acurácia de 72% para 88%. (iii) Correção em excesso prejudica: com viés 1,0, thr. 0,40 e 0,45 **aumentam** o DPD (0,16 e 0,10) e reduzem a acurácia (94% e 95%), pois se corrige um viés inexistente. (iv) O melhor thr. depende do viés: 0,45 para viés 0,9 (DPD 0,023; 100%), 0,40–0,45 para 0,85 e 0,50 para 1,0. *Ressalva:* cada combinação usa amostra aleatória nova (sem `seed`), logo valores variam entre execuções (ex.: viés 1,0/thr. 0,50 dá DPD 0,009 aqui e 0,035 na célula 48).

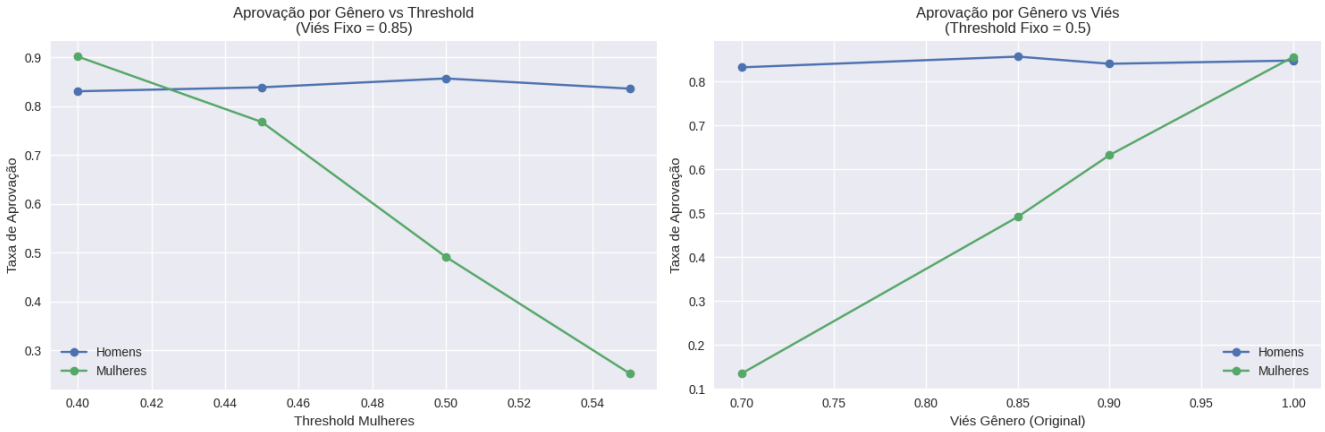


Figura 2: Célula 47, a partir da tabela da célula 43. Esquerda: taxas × thr. das mulheres (viés 0,85). Direita: taxas × viés (thr. 0,50).

B.2 Célula 47 — Taxas de aprovação por gênero

Interpretação. A taxa dos homens fica estável (≈83–86%), pois o thr. masculino e seu *score* não mudam. Na esquerda, com viés 0,85, a taxa feminina cai de 90,1% (thr. 0,40) para 25,3% (0,55) e cruza a masculina perto de 0,42: abaixo desse ponto há *sobrecorreção* (mulheres aprovadas mais que homens). Na direita, com thr. igual para ambos, a taxa feminina sobe de 13,5% (viés 0,7) para 85,6% (viés 1,0) e converge à masculina: o viés multiplicativo desloca toda a distribuição de *scores* das mulheres para baixo, e pequenas penalizações geram quedas grandes porque muitos *scores* ficam próximos do corte. *Nota:* o texto da célula 45 cita 47,4%/76,9%/92,9%, mas a tabela da célula 43 mostra 49,1%/76,7%/90,1% (thr. 0,50/0,45/0,40); os valores variam por falta de `seed`.

B.3 Célula 48 — Viés 1,0 vs. 0,8 (mesma amostra, `seed`=42)

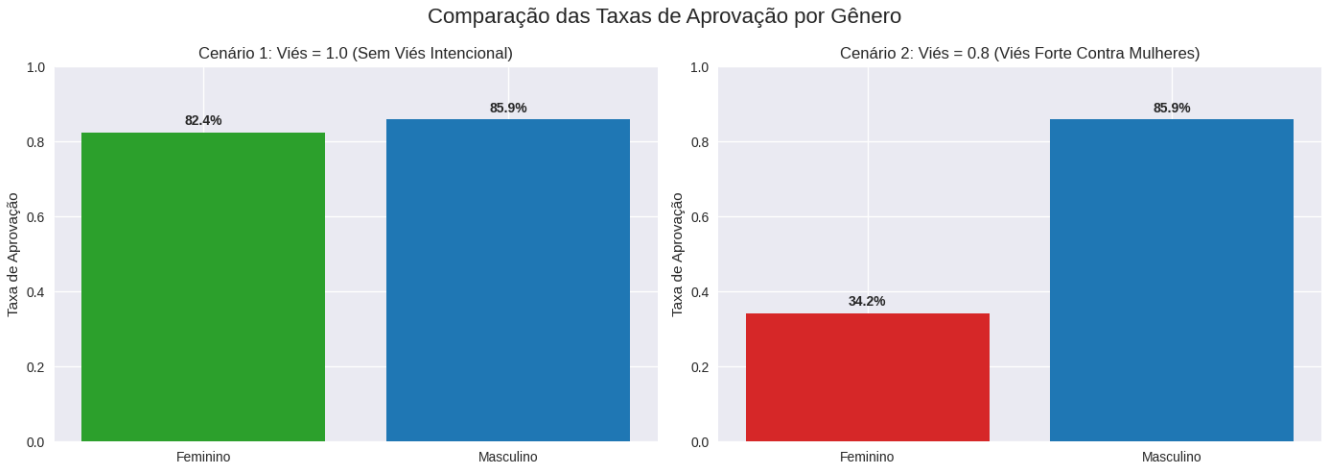


Figura 3: Célula 48. Taxas de aprovação por gênero com viés 1,0 e 0,8 (mesmos clientes, thr. 0,50).

Resultado impresso: DPD (viés 1,0) = 3,5%; DPD (viés 0,8) = 51,7%. Como a `seed` fixa gera exatamente as mesmas pessoas, a única mudança entre os painéis é o fator 0,8 aplicado ao *score* feminino: mulheres passam de 82,4% para 34,2% e homens ficam em 85,9%. Isso isola o efeito do viés. A diferença de 3,5% no painel esquerdo é puro acaso amostral.

B.4 Célula 49 — Trade-off fairness × acurácia (viés 0,8)

Resultado impresso:

- thr. 0,50 (sem mitigação): DPD 51,7%, acurácia 80,8%;
- thr. 0,45: DPD 25,0%, acurácia 91,5%;
- melhor thr. (mínimo DPD com acurácia > 70%) = 0,39: DPD 0,7%, acurácia 98,4%;
- "Preço" impresso: −17,5%. O sinal negativo indica que a acurácia **aumenta** 17,5 p.p. em relação ao modelo sem mitigação; contra o modelo sem viés (100%), o custo é 1,6 p.p.

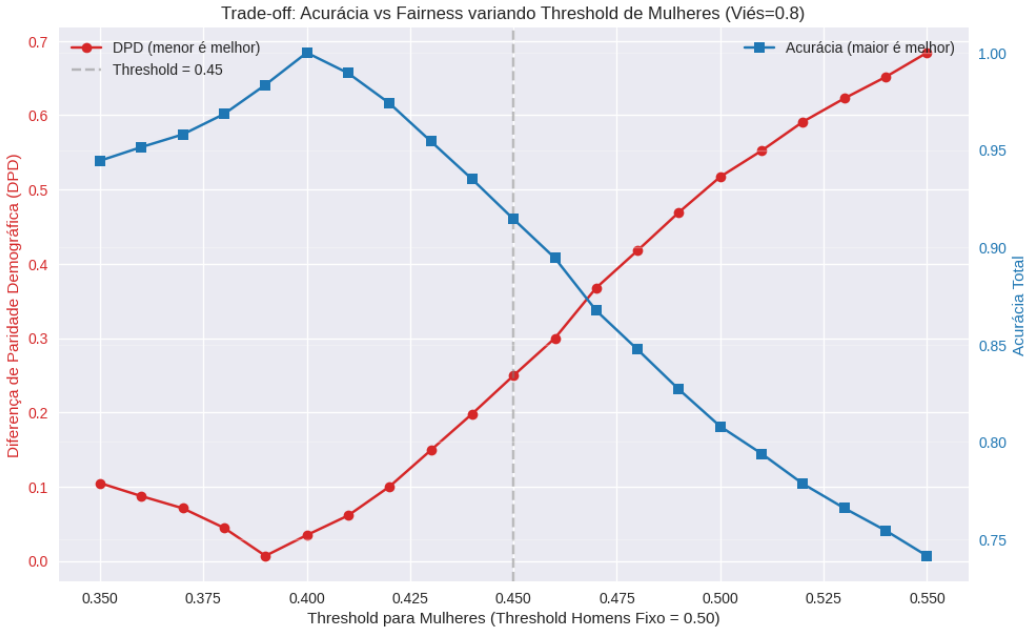


Figura 4: Célula 49. DPD (vermelho, eixo esquerdo) e acurácia (azul, eixo direito) × thr. das mulheres (0,35–0,55; homens = 0,50).

Interpretação. O DPD tem mínimo em 0,39 (*valley* da curva vermelha) e a acurácia máxima (100%) em 0,40: como $0{,}5 \times 0{,}8 = 0{,}4$, o thr. 0,40 anula exatamente o viés, e o ponto de DPD mínimo difere ligeiramente pela discretização dos *scores* amostrados. Acima de 0,40 a acurácia cai e o DPD cresce quase linearmente; abaixo, ocorre sobrecorreção, aprovando mulheres que o *score* base reprovaria. Neste cenário fairness e acurácia caminham juntas, porque o "*ground truth*" é o *score* sem viés.