Relatório: Análise XAI do Impacto da IA nas Profissões (2030)

Ética em Inteligência Artificial — Explicabilidade com LIME e SHAP

Jefferson Cunha — `jefferson.cunha@ufpe.br`

Disciplina: Ética e Inteligência Artificial — 2º sem/2026 — Prof. Geber Ramalho

Metodologia. Usei o *dataset AI Impact on Jobs 2030* (3000 registros, 20 cargos, 10 *skills*). O alvo é `Automation_Probability_2030`. Treinei um `RandomForestRegressor` (`random_state`=101, 70/30) e expliquei com SHAP (`TreeExplainer`, 500 instâncias) e LIME (instância 221, `seed`=42). `Education_Level` é ordinal e `Job_Title` é *one-hot*. `Risk_Category` foi removida por **vazamento do alvo** (Low 0,05–0,30; Medium 0,31–0,70; High 0,71–0,95). Experimentos: **Exp1** remove `Skill_1` e `Skill_5` (maiores |corr| com o alvo entre as *skills*: +0,031 e −0,026); **Exp2** remove `AI_Exposure_Index` e `Years_Experience` (corr. +0,014 e −0,018).

1. Desempenho preditivo

Modelo	R^2	RMSE	MAE	R^2 (5 *seeds*)	Predição inst. 221
Baseline	0,8494	0,0983	0,0819	0,8485 ± 0,0013	0,146
Exp1 (sem `Skill_1`, `Skill_5`)	0,8498	0,0982	0,0815	0,8488 ± 0,0010	0,149
Exp2 (sem `AI_Exp.`, `Years_Exp.`)	0,8482	0,0987	0,0825	0,8475 ± 0,0014	0,145

Valor real da instância 221: 0,23. As três versões diferem em ≤0,002 de R^2, o que é da ordem do desvio entre *seeds* do Random Forest. Ou seja, **remover essas quatro variáveis não altera o modelo de forma mensurável**.

2. SHAP — interpretação global

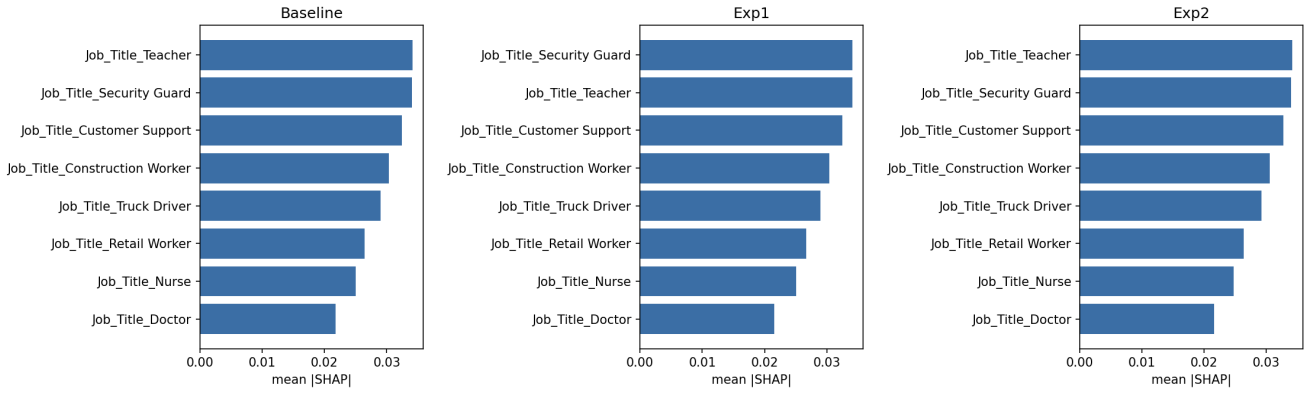


Figura 1: Importância global (média de |SHAP|, 8 maiores) nas três versões.

As colunas `Job_Title_*` somam **0,271 dos 0,307** de importância total no baseline (**88%**). As dez maiores são todas de cargo (`Teacher` 0,034; `Security Guard` 0,034; `Customer Support` 0,032). As dez *skills* juntas somam apenas 0,022 (7%), e as demais variáveis (salário, experiência, escolaridade, exposição à IA, crescimento tecnológico) completam o resto, abaixo de 0,04. Nos Exp1 e Exp2 a importância dos cargos muda no quarto decimal (0,2713 e 0,2722): o ranking é idêntico.

3. LIME — interpretação local

Nas três versões as cinco *features* são `Job_Title_*`, com pesos de ±0,25 a 0,29 (por ex., `Security Guard` ≤ 0: −0,29; `Research Scientist` ≤ 0: +0,25). Isto é coerente com o SHAP: a predição baixa (0,15) vem de o cargo da pessoa não ser um dos de alto risco. Repetindo o LIME com 20 *seeds*, **100%** das *features* do top-5 foram cargos nos três modelos, mas houve 9 conjuntos distintos de top-5. A ordem e quais cargos aparecem variam por amostragem do LIME, então diferenças entre execuções não devem ser lidas como efeito dos experimentos.

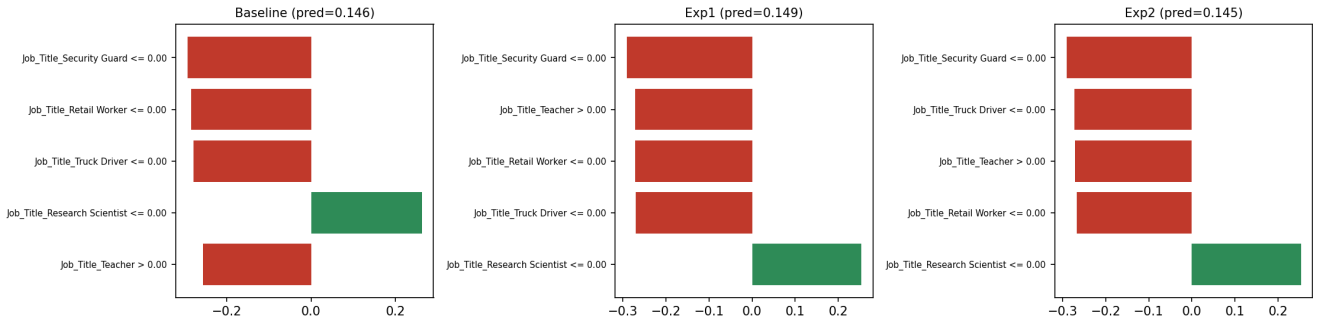


Figura 2: LIME da instância 221 (5 *features*), vermelho reduz e verde aumenta a probabilidade.

4. Discussão e melhor modelo

- **O modelo é praticamente uma tabela por cargo.** Com 88% da importância em `Job_Title`, as demais correlações ($|r| \leq 0{,}03$ com o alvo) são ruído. As explicações de SHAP e LIME concordam em substância, o que dá confiança à interpretação e indica que o *dataset* é provavelmente sintético.
- **Melhor modelo.** O Exp1 tem o melhor desempenho numérico (R^2 0,8498), mas a vantagem de 0,0004 é menor que o desvio entre *seeds*. Recomendo o **Exp1**: desempenho equivalente ou ligeiramente melhor, duas *features* a menos e explicações idênticas. O Exp2 é o pior numericamente, ainda que dentro do ruído.
- **Sem relação causal.** Não se pode concluir que *skills*, experiência ou exposição à IA não afetam a automação real. Apenas que, neste *dataset*, não carregam sinal.

5. Reflexões éticas e limitações

- **Julgar pessoas pelo cargo.** Um modelo que decide pelo cargo trata indivíduos como média da categoria: um(a) professor(a) altamente qualificado(a) recebe o mesmo risco que qualquer outro. Para políticas de requalificação, isso é um *proxy* grosseiro e pode estigmatizar profissões. XAI é o que torna essa dependência visível.
- **Vazamento.** Sem remover `Risk_Category`, o modelo apenas reconstruiria o alvo e SHAP/LIME explicariam um artefato. Explicabilidade só é confiável se o modelo o for.
- **Escopo.** O enunciado fala em programação, mas usei todos os cargos do *dataset*, sem filtro. O LIME trata *one-hot* como contínuo (`<= 0,00`); declarar `categorical_features` tornaria o texto mais legível.

6. *Lessons learned*

A explicabilidade revelou o que as métricas escondiam: um R^2 de 0,85 vindo quase inteiramente de uma única variável categórica. Remover *features* sem sinal não mudou desempenho nem explicação, e o LIME precisa ser repetido com *seeds* diferentes antes de se interpretar uma instância isolada.